HAL open science

L'Intelligence Artificielle Neuro-symbolique dans la Conception Accélérée pour l'Impression 4D : État, Défis et Perspectives

Oualid Bougzime, Christophe Cruz, Frédéric Demoly

To cite this version:

Oualid Bougzime, Christophe Cruz, Frédéric Demoly. L'Intelligence Artificielle Neuro-symbolique dans la Conception Accélérée pour l'Impression 4D : État, Défis et Perspectives. Colloque S.Mart 2025, GIS S.Mart RAO, May 2025, Vogüé (Ardèche - France), France. hal-05244947

HAL Id: hal-05244947

https://hal.science/hal-05244947v1

Submitted on 8 Sep 2025

HAL is a multi-disciplinary open access archive for the deposit and dissemination of scientific research documents, whether they are published or not. The documents may come from teaching and research institutions in France or abroad, or from public or private research centers.

L'archive ouverte pluridisciplinaire **HAL**, est destinée au dépôt et à la diffusion de documents scientifiques de niveau recherche, publiés ou non, émanant des établissements d'enseignement et de recherche français ou étrangers, des laboratoires publics ou privés.

Autorisation HAL

HAL Authorization

Smart
Systems.Manufacturing.Academics.Resources.Technologies
19ème colloque national
13-15 mai 2025, Vogüé
Recherche et enseignement agiles pour une industrie soutenable

L'Intelligence Artificielle Neuro-symbolique dans la Conception Accélérée pour l'Impression 4D : État, Défis et Perspectives

Oualid Bougzime[a,*], Christophe Cruz[b], Frédéric Demoly[a,e]

[a] ICB UMR 6303 CNRS, Université Marie et Louis Pasteur, UTBM, 90010 Belfort Cedex, France
[b] ICB UMR 6303 CNRS, Université Bourgogne Europe, 21078 Dijon, France
[e] Institut universitaire de France (IUF), Paris, France

* e-mail : oualid.bougzime@utbm.fr

1. Introduction

L'impression 4D est un paradigme de fabrication qui combine la fabrication additive (AM) avec des matériaux intelligents (SMs), permettant aux objets imprimés de modifier leur forme, leurs propriétés ou leur fonctionnalité au fil du temps lorsqu'ils sont exposés à des stimuli tels que la température, la lumière, l'humidité, les champs magnétiques/électriques, la chimie ou le pH [1]. Ces changements permettent aux objets de s'étendre, se contracter, se plier ou se transformer sans intervention mécanique. Ce domaine a évolué rapidement grâce à des innovations en science des matériaux, AM, chimie et mécanique computationnelle, avec des applications potentielles dans la biomédecine, la robotique souple, le textile, l'automobile, la défense et l'espace [2, 3]. Au cœur de l'impression 4D, l'intégration de matériaux réactifs aux stimuli, tels que les polymères à mémoire de forme (SMPs), les élastomères à cristaux liquides (LCEs), les alliages à mémoire de forme (SMAs), les polymères électroactifs (EAPs) et les hydrogels, permet de créer des géométries sophistiquées via des techniques d'AM comme la Fused Filament Fabrication (FFF), Direct Ink Writing (DIW), Digital Light Processing (DLP) et Power-Bed Fusion (PBF) [4]. Ces matériaux peuvent être programmés pour changer de forme en réponse à des stimuli spécifiques, comme les SMPs qui retrouvent leur forme d'origine lorsqu'ils sont chauffés, ou les hydrogels qui réagissent aux variations d'humidité, température, ionique ou de pH, ce qui les rend particulièrement adaptés aux applications biomédicales [5].

Les recherches actuelles en impression 4D se concentrent sur l'amélioration de l'imprimabilité, de la sensibilité aux stimuli, de la résistance à la fatigue fonctionnelle et des performances mécaniques des SMs [6]. Cependant, des défis demeurent pour prédire et contrôler le comportement des matériaux réactifs aux stimuli, notamment pour cibler des propriétés complexes [5]. Un contrôle précis des transformations des matériaux est essentiel pour garantir le bon fonctionnement des structures imprimées en 4D dans les applications réelles, et le développement de structures multi-matériaux, où des matériaux aux propriétés diverses doivent se lier efficacement et travailler ensemble sous stimulation, représente également un défi majeur. Pour surmonter ces obstacles, l'intelligence computationnelle, prenant en compte les interactions dynamiques entre matériaux actifs et passifs, peut accélérer l'exploration et la découverte des matériaux et structures, tout en améliorant leur imprimabilité et leurs performances. Les méthodologies avancées comme la conception inverse permettent de déterminer la composition optimale des matériaux et l'architecture de conception à partir des propriétés et comportements cibles [7, 8]. Ce processus facilite la création de matériaux et structures sur mesure, répondant à des critères de performance spécifiques. L'apprentissage automatique (Machine Learning, ML) est essentiel dans ce cadre pour modéliser des ensembles complexes de données et prédire le comportement des matériaux [9].

L'essor de l'apprentissage profond (Deep Learning, DL), qui automatise l'extraction des caractéristiques via des réseaux neuronaux (Neural Networks, NNs), a permis des percées dans des domaines comme la vision par ordinateur, le traitement du langage naturel (Natural Language Processing, NLP) et la conduite autonome, où de grands ensembles de données sont traités efficacement [10]. Le DL repose sur des NNs constitués de couches de

neurones artificiels qui apprennent des motifs complexes et améliorent leur précision prédictive. Cependant, les NNs rencontrent des difficultés dans les tâches nécessitant raisonnement logique, explicabilité et interprétabilité, essentielles pour des applications à enjeux élevés [11]. L'intelligence artificielle symbolique (Symbolic AI) offre une approche complémentaire avec un raisonnement structuré, tandis que l'intelligence artificielle neuro-symbolique (NSAI) combine ces deux méthodes, en s'inspirant des théories de la cognition humaine, où les NNs assurent un traitement rapide et intuitif, et le raisonnement symbolique apporte une réflexion logique [12, 13].

Ainsi, cet article vise à explorer de nouvelles opportunités de conception pour l'impression 4D et à guider les futures recherches axées sur l'amélioration des propriétés des matériaux actifs et des performances des structures pour libérer les applications réelles. La section 2 rappelle les principaux travaux dans la conception inverse pour l'impression. La section 3 étudie le potentiel de la NSAI comme outil transformateur pour résoudre ces défis. Elle met en lumière les avantages de combiner le ML avec le raisonnement symbolique pour améliorer l'explicabilité et l'interprétabilité. Ensuite, la section 4 présente les orientations de recherche futures nécessaires pour accélérer le développement des SMs de nouvelle génération et des structures transformables, ainsi que la découverte d'applications latentes.

2. CONCEPTION INVERSE ASSISTÉE PAR L'IA

Grâce à la conception inverse, la composition et la distribution des matériaux, les paramètres d'impression et les propriétés souhaitées peuvent être déterminés de manière systématique pour obtenir des formes cibles précises et des performances optimales. En science des matériaux, des progrès significatifs ont été réalisés en utilisant le ML pour prédire et optimiser les propriétés mécaniques des matériaux composites et hétérogènes. Par exemple, les réseaux neuronaux convolutifs (CNNs) prédisent le module effectif des composites, permettant des itérations de conception rapides [14]. Toutefois, l'optimisation simultanée des paramètres compromet la précision des formes et la performance mécanique.

Des méthodes hybrides intégrant le ML avec des algorithmes évolutionnaires (EA) ont optimisé les réponses aux changements de forme dans les structures composites actives imprimées en 4D, offrant des solutions de conception inverse plus rapides [15]. Les simulations par éléments finis (FE) combinées avec les EA explorent les conceptions de poutres composites actives avec des distributions de matériaux au niveau du voxel, améliorant ainsi l'optimisation des formes [7]. Les modèles ML comme ResNet et les NNs inverses réduisent les coûts de calcul, permettant des prédictions plus rapides et plus précises pour des problèmes complexes de conception inverse [8] (Figure 1a,b). Ces modèles ont démontré un succès remarquable dans la gestion de problèmes complexes et de haute dimension de conception inverse, tels que le flambement des mésosurfaces et les membranes composites gonflables. Athinarayanarao et al. [16] ont optimisé l'utilisation des matériaux actifs dans des structures composites actives 3D en utilisant une approche basée sur les voxels avec un vide comme troisième matériau (Figure 1e). Ces approches sont freinées par la complexité des espaces de conception à haute dimension, limitant leur potentiel d'optimisation.

De plus, les réseaux neuronaux informés par la physique (PINNs), introduits par Raissi et al. [17], ont été appliqués à des problèmes inverses comme la caractérisation des matériaux, où ils permettent d'identifier les propriétés des matériaux hétérogènes à partir de données de déformation observées. Cette approche innovante intègre directement les lois physiques dans les modèles ML afin d'améliorer la précision dans l'identification des propriétés des matériaux. Les modèles génératifs profonds, tels que les réseaux antagonistes génératifs (GANs) et les auto-encodeurs variationnels (VAEs), sont utilisés pour concevoir des métamatériaux mécaniques avec des propriétés anisotropes adaptées, facilitant ainsi la découverte de nouveaux matériaux avec des propriétés mécaniques cibles. Cependant, les distributions de matériaux peuvent poser des problèmes d'imprimabilité, notamment avec des matériaux dissemblables. Benyahia et al. [18] ont développé une approche de conception computationnelle convertissant les distributions basées sur les voxels en blocs emboîtables pour un assemblage manuel ou robotisé (Figure 1d). Sun et al. [19] ont utilisé des réseaux neuronaux récurrents (RNNs) pour prédire précisément la distribution des matériaux dans des structures composites actives réagissant aux stimuli environnementaux (Figure 1c). La conversion des distributions voxelaires en configurations assemblables et la précision de la prédiction limitent l'imprimabilité.

Cependant, pour exploiter pleinement le potentiel du ML, notamment lorsqu'on travaille avec de petits ensembles de données ou lorsque des explications détaillées sont requises dans les recherches quantitatives, l'intégration de l'IA symbolique devient cruciale. Cela est particulièrement pertinent pour le domaine émergent de l'impression 4D. L'IA symbolique complète les approches basées sur les données en structurant les connaissances de base et en fournissant des résultats plus transparents et interprétables. Cette intégration garantit que les découvertes basées sur le ML dans l'impression 4D sont non seulement précises, mais aussi facilement validables, les rendant ainsi plus applicables aux scénarios réels.

Les recherches complémentaires sur l'IA symbolique pour l'impression 4D ont été avancées par Dimassi et al. [20], qui ont développé une ontologie pour structurer et formaliser les connaissances relatives aux stimuli, aux SMs, à la conception de produits et à la AM. Cette ontologie de domaine garantit que les connaissances sont accessibles et interopérables à travers les différents domaines. Les ontologies fournissent une base pour les procédures de raisonnement, offrant un soutien à la décision dans le choix des matériaux et des processus, les recommandations de conception et l'alignement des pratiques d'impression 4D avec les normes émergentes.

En permettant des mises à jour en temps réel et un raisonnement sur des connaissances structurées, les ontologies comblent l'écart entre l'IA symbolique et l'IA neuronale, favorisant une stratégie de conception plus holistique et contextuellement consciente [21]. L'intégration de ces connaissances structurées dans des cadres plus larges de conception et d'informatique des matériaux est cruciale pour l'avenir de l'impression 4D.

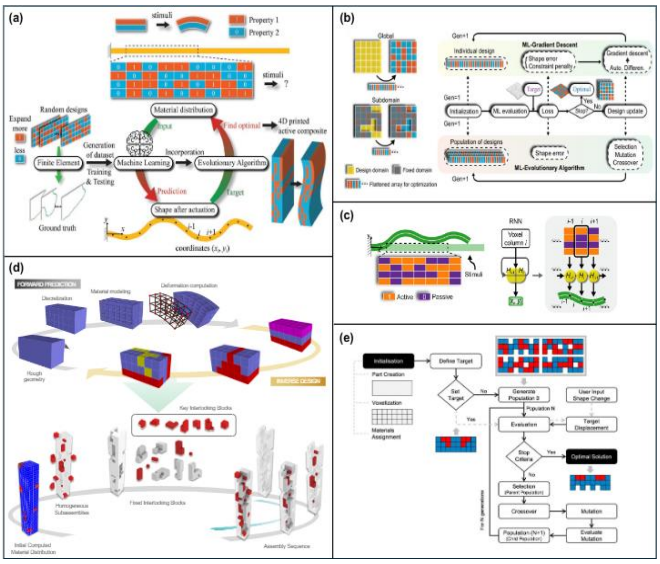

Figure 1 - Architectures de conception inverse et d'optimisation des structures multi-matériaux imprimées en 4D.

3. L'ESSOR DE L'IA NEURO-SYMBOLIQUE

Bien que les NNs soient excellents pour reconnaître les motifs dans les données, ils ont souvent des difficultés lorsqu'ils sont confrontés à des situations qu'ils n'ont jamais rencontrées auparavant [11]. D'un autre côté, le raisonnement symbolique offre un cadre logique pour la prise de décision, mais il est limité dans sa capacité à acquérir des connaissances à partir de nouvelles données et à s'adapter de manière dynamique. En combinant ces deux approches, le NSAI parvient à combler les lacunes et à créer un système d'IA plus adaptable, interprétable et efficace (Figure 2).

L'une des caractéristiques distinctives de la NSAI est sa capacité à généraliser au-delà de ses données d'entraînement. Les modèles d'IA traditionnels échouent souvent lorsqu'ils rencontrent quelque chose de nouveau, mais la NSAI, avec son mélange d'apprentissage et de logique, peut mieux gérer ces situations. De plus, la NSAI peut offrir une meilleure interprétabilité du processus de prise de décision dans la conception pour l'impression 4D, en fournissant des informations sur la façon et la raison pour lesquelles certaines décisions de conception sont prises, rendant cette approche à la fois plus fiable et précieuse. Un autre avantage important de la NSAI est sa nécessité réduite de grands ensembles de données. Les systèmes d'IA traditionnels nécessitent souvent des quantités massives de données pour bien fonctionner, ce qui peut être coûteux en termes de temps et de ressources. Cependant, la NSAI peut atteindre de bonnes performances avec bien moins de données, grâce à sa capacité à raisonner de manière symbolique. Cela en fait une option plus durable et pratique, notamment pour les petites organisations ou les domaines de recherche émergents travaillant avec des ressources limitées. En plus de cette efficacité des données, les modèles NSAI montrent également une remarquable transférabilité, ce qui signifie qu'ils peuvent appliquer ce qu'ils ont appris dans un domaine à un autre avec un minimum de réentraînement. Cela est particulièrement utile dans les situations où il y a peu de données disponibles pour une nouvelle tâche [13].

Ce qui distingue vraiment la NSAI, ce sont ses capacités de raisonnement améliorées. Bien que les NNs soient compétents pour détecter les corrélations et les structures sous-jacentes dans les ensembles de données, ils sont souvent limités dans les tâches nécessitant un raisonnement logique ou une résolution de problèmes. La NSAI comble cette lacune en gérant des défis plus complexes. De plus, la NSAI est hautement évolutive et adaptable, ce qui lui permet de résoudre des problèmes de plus en plus complexes dans divers domaines. Sa capacité à combiner le traitement de données non structurées avec une logique structurée signifie qu'elle peut continuer à croître et à évoluer à mesure que les technologies de l'IA progressent, positionnant ainsi la NSAI comme un acteur clé dans l'avenir des systèmes basés sur l'IA [12].

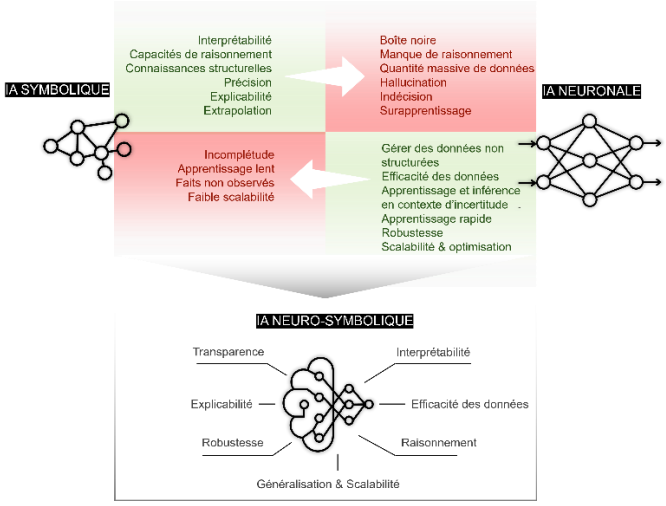

Figure 2 - NSAI comme une combinaison des forces de l'IA symbolique et de l'IA neuronale.

4. OPPORTUNITÉS DANS LA CONCEPTION POUR L'IMPRESSION 4D

Les réalisations actuelles de la NSAI et les défis dans la conception de matériaux actifs et de structures transformables utilisant l'impression 4D ont mis en évidence la nécessité d'une exploration plus approfondie de la formulation et de la distribution des matériaux, tout en maintenant un contrôle sur les résultats générés par l'IA. Les sections suivantes présentent les principales opportunités dans la conception pour l'impression 4D, illustrées dans (Figure 3), qui offre une vue d'ensemble.

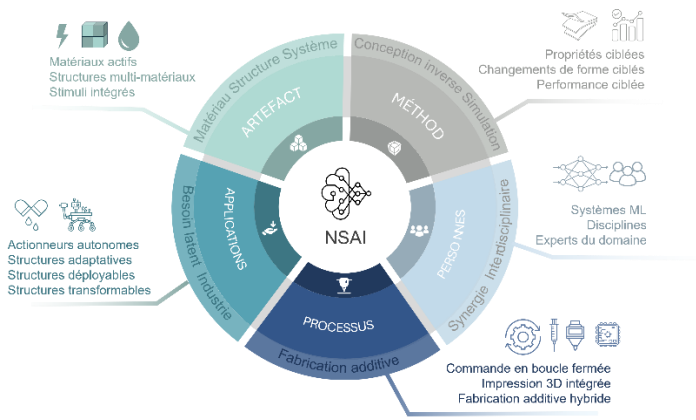

Figure 3 - Vue d'ensemble de la NSAI dans la conception accélérée pour l'impression 4D en ce qui concerne l'AM, les personnes impliquées de divers domaines, les artefacts et les applications.

4.1. Intégration Multidisciplinaire et Cohérence

La nature interdisciplinaire de l'impression 4D présente des défis considérables pour intégrer l'expertise de divers domaines tels que l'ingénierie, la conception, la science des matériaux, l'AM, la mécanique computationnelle, la chimie, la physique et l'informatique. Chaque domaine apporte ses propres données, contraintes, méthodologies et terminologies, rendant difficile l'établissement de processus de conception cohérents et coordonnés. L'intégration efficace nécessite de prendre en compte plusieurs acteurs (architecte du produit, concepteur mécanique, expert en matériaux, planificateur de processus AM) et de gérer des complexités telles que les structures multi-matériaux, les différentes techniques AM, les fonctionnalités, les principes physiques, les échelles et les dimensions temporelles. La NSAI facilite cette intégration en permettant aux experts de différents domaines de travailler dans un cadre partagé et explicable.

Dans un contexte industriel, l'intégration implique également de naviguer entre des départements distincts (ingénierie, fabrication, production), chacun ayant ses objectifs, priorités et méthodes. Ces départements fonctionnent différemment par rapport à l'approche axée sur les disciplines en recherche, l'industrie utilisant des structures spécifiques pour répondre aux défis pratiques. La NSAI comble l'écart entre l'orientation théorique de la recherche et l'organisation pratique de l'industrie, facilitant ainsi la conception collaborative.

4.2. Favoriser la Collaboration Entre les Acteurs du ML et de l'Impression 4D

La NSAI sert d'interface clé entre les experts humains et les systèmes de ML en permettant l'explicabilité, comblant l'écart entre la nature opaque des modèles ML et la clarté nécessaire pour une prise de décision éclairée. L'explicabilité permet aux experts de comprendre, valider et modifier les conclusions du modèle, renforçant ainsi la confiance dans les décisions en accord avec leurs connaissances du domaine. Les experts, souvent dotés de connaissances spécifiques difficiles à encoder dans les modèles ML traditionnels, peuvent intégrer leurs insights qualitatifs dans le processus de décision via un raisonnement symbolique. Cette intégration améliore la précision et la pertinence des prédictions en appliquant des règles et contraintes définies par les experts, limitant les sorties du modèle à des scénarios réalistes. L'explicabilité permet aussi aux experts de perfectionner le modèle, en retraçant les décisions non satisfaisantes et en ajustant la couche de raisonnement symbolique, alignant ainsi le modèle avec les besoins réels.

4.3. Amélioration des processus AM

Les techniques de ML ont un grand potentiel pour optimiser les processus et améliorer la qualité d'impression en AM, mais elles rencontrent des limitations liées à la complexité des techniques et des données disponibles [22, 23]. Ces défis incluent la variabilité des paramètres de processus, la dépendance à de grands ensembles de données, l'incapacité à détecter des défauts inconnus, des problèmes d'interprétabilité et d'intégration, ainsi que le coût élevé de la surveillance en temps réel. Les réseaux neuronaux profonds (Deep NNs) peinent à capturer les interactions dynamiques entre les paramètres, et la diversité des matériaux, techniques et géométries complique l'obtention des ensembles de données nécessaires pour des prédictions précises [24]. De plus, les modèles supervisés ne détectent pas les défauts inconnus, étant limités par des données étiquetées historiques. Les techniques de traitement d'images, comme les CNNs, requièrent également des données étiquetées substantielles, souvent absentes en AM, et sont sensibles aux variations des conditions d'imagerie (par exemple, l'éclairage ou l'angle de la caméra).

Le manque d'interprétabilité des modèles complique la détection des causes des défauts et l'implémentation de solutions correctives. De plus, la surveillance en temps réel nécessite des capteurs coûteux et des données volumétriques difficiles à valider. Ces limitations soulignent la nécessité d'approches ML plus robustes pour gérer la variabilité des techniques AM, réduire la dépendance aux grands ensembles de données et améliorer l'interprétabilité. La NSAI répond à ces défis en intégrant des connaissances spécifiques au domaine dans le processus d'apprentissage, en permettant la détection de défauts inconnus par raisonnement basé sur des règles, même avec des données étiquetées limitées. En outre, la NSAI permet une utilisation plus efficace des données et une prise de décision en temps réel plus robuste, faisant d'elle une solution idéale pour les applications 3D/4D, où la collecte de données est souvent coûteuse.

4.4. Optimisation des Structures Multi-Matériaux et Métamatériaux

Le développement des métamatériaux mécaniques avec le ML présente des défis en matière de conception et de validation expérimentale. Ces matériaux nécessitent des modèles sophistiqués pour prédire les performances, en particulier pour des structures hiérarchiques à

plusieurs échelles comme des réseaux, plaques et coques. L'intégration de conceptions complexes avec des paramètres d'impression est cruciale pour répondre à des contraintes telles que la rigidité, la dissipation thermique et le coût. Bien que des outils comme les méthodes par éléments finis et les algorithmes d'optimisation topologique améliorent progressivement les conceptions, ils sont limités par de vastes espaces de conception et de fortes exigences computationnelles [25, 26]. De plus, la validation expérimentale des métamatériaux prédits reste un obstacle majeur, nécessitant des processus de fabrication et des tests rigoureux.

La NSAI surmonte ces défis en optimisant l'espace de solution et en garantissant que les conceptions respectent les contraintes de fonctionnalité et d'imprimabilité. Elle combine des stratégies biologiques, comme les automates de voxels et la morphogenèse numérique, et adopte une approche de conception inverse pour identifier et adapter les modèles de distribution des matériaux selon des critères tels que la forme, la résistance, la flexibilité et la réactivité aux stimuli. La NSAI intègre l'IA symbolique pour affiner ces modèles, assurant leur conformité aux lois physiques et aux contraintes des experts, même dans des conditions extrêmes. Lorsque les ensembles de données sont limités, les PINNs offrent une solution en intégrant directement les lois physiques, mais l'IA symbolique comble leur manque de polyvalence pour des besoins de conception complexes. Cette combinaison permet une approche plus adaptable et complète, maintenant de hautes performances même avec peu de données [8, 27].

L'intégration de la NSAI dans l'impression 4D multi-matériaux offre une solution stratégique pour surmonter les limitations actuelles. En combinant l'apprentissage des NNs avec le raisonnement logique de l'IA symbolique, la NSAI facilite la conception, l'optimisation et la simulation de structures multi-matériaux à diverses échelles. Cela accélère la découverte et améliore la précision des conceptions pour des applications réelles. Le futur de la NSAI dans les structures multi-matériaux repose sur sa capacité à intégrer l'analyse prédictive avec des capacités d'adaptation en temps réel, permettant la création de structures intelligentes avec des capacités d'auto-surveillance et d'auto-ajustement, augmentant ainsi la performance, la résilience et la longévité dans des environnements complexes.

4.5. Exploration et Découverte de Nouvelles Compositions de Matériaux

La découverte et l'intégration de nouveaux matériaux, en particulier dans les conceptions multi-matériaux et métamatériaux, est essentielle pour l'impression 4D. L'immense espace de conception des matériaux complique la compréhension des interactions et des réponses aux stimuli. Les NNs sont efficaces pour identifier les motifs dans le comportement des matériaux, mais manquent de la capacité d'expliquer pourquoi certaines combinaisons fonctionnent. La NSAI surmonte ces limitations en intégrant le raisonnement symbolique, permettant de générer des combinaisons de matériaux basées sur des données et d'incorporer les hypothèses des experts. En combinant l'exploration de configurations vastes par les NNs et l'encodage de contraintes de performance par l'IA symbolique, la NSAI évalue systématiquement les combinaisons qui satisfont plusieurs critères.

Les hypothèses des experts, issues des recherches de pointe, peuvent être encodées dans le système symbolique pour guider l'exploration des matériaux, priorisant les combinaisons selon des critères comme la performance mécanique, la stabilité environnementale ou la biocompatibilité. Lorsqu'un NN propose des candidats matériels, le système symbolique les évalue pour s'assurer de leur conformité avec les principes scientifiques, comblant ainsi l'écart entre données et raisonnement. La NSAI améliore le processus en vérifiant les prédictions des NNs par raisonnement symbolique, garantissant que les matériaux proposés sont viables chimiquement et répondent aux critères de performance. Elle applique des règles basées sur des principes scientifiques pour valider les combinaisons de matériaux, assurant qu'elles sont non seulement innovantes mais aussi réalisables et techniquement viables.

4.6. Découverte des Applications Émergentes

La NSAI explore des données structurées et non structurées dans divers secteurs, utilisant des bases de données de brevets, des rapports industriels et de la littérature scientifique pour identifier des motifs, tendances et opportunités d'applications pour l'impression 4D. En détectant de manière proactive les besoins non satisfaits et les innovations émergentes, la NSAI positionne l'impression 4D comme une technologie capable de répondre aux défis du monde réel. Elle analyse les dépôts de brevets, les données industrielles et les tendances des marchés pour repérer des lacunes technologiques et orienter les efforts vers des applications à fort impact.

Au-delà des applications industrielles, la NSAI exploite des disciplines comme la biologie, la physique et la chimie. En analysant des données biologiques, elle utilise les NNs pour identifier des relations cachées, suggérer des conceptions biomimétiques et proposer de nouvelles applications bio-inspirées pour l'impression 4D, comme l'ingénierie tissulaire et les implants intelligents. Cette capacité interdisciplinaire permet d'appliquer l'impression 4D dans des domaines novateurs. La NSAI synthétise à la fois des connaissances structurées et non structurées pour offrir une vue d'ensemble des applications potentielles. La synergie entre les NNs et l'IA symbolique facilite la découverte d'applications interdisciplinaires, libérant ainsi tout le potentiel de l'impression 4D.

5. Conclusion

L'intégration de la NSAI dans l'impression 4D est cruciale pour aborder les complexités de la conception multi-

matériaux, de la réactivité aux stimuli et de la collaboration interdisciplinaire. Avec la croissance rapide de ce domaine, le besoin de contrôler précisément le comportement des matériaux, d'avoir des cadres de conception évolutifs et des processus décisionnels transparents devient essentiel. La NSAI comble les lacunes entre des domaines comme la science des matériaux, la chimie, l'AM, la mécanique, l'ingénierie et l'optimisation, tout en améliorant les méthodes computationnelles existantes. En synthétisant des données diverses et en fournissant des recommandations explicables, elle permet aux experts de naviguer avec une précision inédite dans les interactions complexes entre matériaux et stimuli. Cette transparence favorise la collaboration entre disciplines, optimisant la composition, la distribution des matériaux, l'impression et le contrôle des stimuli à différentes échelles. La NSAI ouvre ainsi de nouvelles possibilités d'innovation, permettant le développement de structures imprimées en 4D plus fiables et adaptées aux besoins spécifiques des secteurs, comme l'ingénierie biomédicale, l'automobile et l'aérospatiale. L'adaptabilité et les capacités décisionnelles de la NSAI seront déterminantes pour l'avenir de l'impression 4D.

REMERCIEMENTS

Cette recherche a été financée par l'Agence Nationale de la Recherche (ANR) dans le cadre de l'initiative « France 2030 » et du programme « DIADEM » 22-PEXD-0016 (« ARTEMIS »).

RÉFÉRENCES

[1] S. Tibbits, "4d printing: multi-material shape change," Architectural design, vol. 84, no. 1, pp. 116–121, 2014.

[2] F. Demoly and J.-C. Andr´e, 4D Printing, Volume 1: Between Disruptive Research and Industrial Applications. John Wiley & Sons, 2022.

[3] F. Demoly and J.-C. Andre, 4D Printing, Volume 2: Between Science and Technology. John Wiley & Sons, 2022.

[4] F. Demoly, M. L. Dunn, K. L. Wood, H. J. Qi, and J.-C. Andr´e, "The status, barriers, challenges, and future in design for 4d printing," Materials & Design, vol. 212, p. 110193, 2021.

[5] M. Bodaghi, L. Wang, F. Zhang, Y. Liu, J. Leng, R. Xing, M. D. Dickey, S. Vanaei, M. Elahinia, S. Van Hoa et al., "4d printing roadmap," Smart Materials and Structures, vol. 33, no. 11, p. 113501, 2024.

[6] F. Demoly and J.-C. Andr´e, "4d printing: bridging the gap between fundamental research and real-world applications," Applied Sciences, vol. 14, no. 13, p. 5669, 2024.

[7] G. Sossou, F. Demoly, H. Belkebir, H. J. Qi, S. Gomes, and G. Montavon, "Design for 4d printing: Modeling and computation of smart materials distributions," Materials & Design, vol. 181, p. 108074, 2019.

[8] X. Sun, L. Yue, L. Yu, H. Shao, X. Peng, K. Zhou, F. Demoly, R. Zhao, and H. J. Qi, "Machine learning-evolutionary algorithm enabled design for 4d-printed active composite structures," Advanced Functional Materials, vol. 32, no. 10, p. 2109805, 2022.

[9] K. T. Butler, D. W. Davies, H. Cartwright, O. Isayev, and A. Walsh, "Machine learning for molecular and materials science," Nature, vol. 559, no. 7715, pp. 547–555, 2018.

[10] J. Zhu, Y. Zhang, and Z. Xu, "Deep learning for ai and computer vision," Frontiers of Information Technology & Electronic Engineering, vol. 18, no. 1, pp. 46–77, 2017.

[11] G. Marcus, "Deep learning: A critical appraisal," arXiv preprint arXiv:1801.00631, 2018.

[12] A. Sheth and K. Roy, "Neurosymbolic value-inspired artificial intelligence (why, what, and how)," IEEE Intelligent Systems, vol. 39, no. 1, pp. 5–11, 2024.

[13] O. Bougzime, S. Jabbar, C. Cruz, and F. Demoly, "Unlocking the Potential of Generative AI through Neuro-Symbolic Architectures: Benefits and Limitations," arXiv preprint arXiv:2502.11269, 2025.

[14] X. Li, Z. Liu, S. Cui, C. Luo, C. Li, and Z. Zhuang, "Predicting the effective mechanical property of heterogeneous materials by image based modeling and deep learning," Computer Methods in Applied Mechanics and Engineering, vol. 347, pp. 735–753, 2019.

[15] X. Sun, K. Zhou, F. Demoly, R. R. Zhao, and H. J. Qi, "Perspective: Machine learning in design for 3d/4d printing," Journal of Applied Mechanics, vol. 91, no. 3, p. 030801, 2024.

[16] D. Athinarayanarao, R. Prod'hon, D. Chamoret, H. J. Qi, M. Bodaghi, J.-C. Andr´e, and F. Demoly, "Computational design for 4d printing of topology optimized multi-material active composites," npj Computational Materials, vol. 9, no. 1, p. 1, 2023.

[17] M. Raissi, P. Perdikaris, and G. E. Karniadakis, "Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations," Journal of Computational physics, vol. 378, pp. 686–707, 2019.

[18] K. Benyahia, H. Seriket, R. Prod'hon, S. Gomes, J.-C. Andr´e, H. J. Qi, and F. Demoly, "A computational design approach for multi-material 4d printing based on interlocking blocks assembly," Additive Manufacturing, vol. 58, p. 102993, 2022.

[19] X. Sun, L. Yu, L. Yue, K. Zhou, F. Demoly, R. R. Zhao, and H. J. Qi, "Machine learning and sequential subdomain optimization for ultrafast inverse design of 4d-printed active composite structures," Journal of the Mechanics and Physics of Solids, vol. 186, p. 105561, 2024.

[20] S. Dimassi, F. Demoly, C. Cruz, H. J. Qi, K.-Y. Kim, J.-C. Andr´e, and S. Gomes, "An ontology-based framework to formalize and represent 4d printing knowledge in design," Computers in Industry, vol. 126, p. 103374, 2021.

[21] F. Demoly, K.-Y. Kim, and I. Horv´ath, "Ontological engineering for supporting semantic reasoning in design: deriving models based on ontologies for supporting engineering design," pp. 405–416, 2019.

[22] X. Peng, S. Wu, X. Sun, L. Yue, S. M. Montgomery, F. Demoly, K. Zhou, R. R. Zhao, and H. J. Qi, "4d printing of freestanding liquid crystal elastomers via hybrid additive manufacturing," Advanced Materials, vol. 34, no. 39, p. 2204890, 2022.

[23] T. Cadiou, F. Demoly, and S. Gomes, "A hybrid additive manufacturing platform based on fused filament fabrication and direct ink writing techniques for multi-material 3d printing," The International Journal of Advanced Manufacturing Technology, vol. 114, no. 11, pp. 3551–3562, 2021.

[24] S. Mondal and S. S. Goswami, "Machine learning techniques for quality assurance in additive manufacturing processes," International Journal of AI for Materials and Design, vol. 1, no. 2, pp. 21–40, 2024.

[25] S. Bonfanti, S. Hiemer, R. Zulkarnain, R. Guerra, M. Zaiser, and S. Zapperi, "Computational design of mechanical metamaterials," Nature Computational Science, vol. 4, no. 8, pp. 574–583, 2024.

[26] W. Sha, M. Xiao, Y. Wang, M. Huang, Q. Li, and L. Gao, "Topology optimization methods for thermal metamaterials: A review," International Journal of Heat and Mass Transfer, vol. 227, p. 125588, 2024.

[27] X. Sun, L. Yue, L. Yu, C. T. Forte, C. D. Armstrong, K. Zhou, F. Demoly, R. R. Zhao, and H. J. Qi, "Machine learning-enabled forward prediction and inverse design of 4d-printed active plates," Nature Communications, vol. 15, no. 1, p. 5509, 2024.