

Utilisation de l'IA agentique et des LLMs pour la génération d'ontologies environnementales

Samir Jabbar, Christophe Cruz

▶ **To cite this version:**

Samir Jabbar, Christophe Cruz. Utilisation de l'IA agentique et des LLMs pour la génération d'ontologies environnementales. Université Bourgogne Europe. 2025. ⟨hal-05340472⟩

HAL Id: hal-05340472

https://hal.science/hal-05340472v1

Submitted on 31 Oct 2025

HAL is a multi-disciplinary open access archive for the deposit and dissemination of scientific research documents, whether they are published or not. The documents may come from teaching and research institutions in France or abroad, or from public or private research centers.

L'archive ouverte pluridisciplinaire **HAL**, est destinée au dépôt et à la diffusion de documents scientifiques de niveau recherche, publiés ou non, émanant des établissements d'enseignement et de recherche français ou étrangers, des laboratoires publics ou privés.



HAL Authorization



Utilisation de l'IA agentique et des LLMs pour la génération d'ontologies environnementales

Rapport mi-parcours

Août 2025

Samir JABBAR | Christophe Cruz

TRACES Project – PRCI franco-suisse (funded by ANR and FNS) – 2022 – 2025

Table des matières

1 Introduction 4
2 État de l'art 5
2.1 Ontologie et apprentissage d'ontologies : définitions et approches classiques 5
2.2 Apports des LLMs et IA Agentique à l'extraction de connaissances 7
2.3 Approach Chain-of-Agents (CoA) 9
3 Méthodologie 10
3.1 Sources textuelles et corpus utilisés 10
3.2 CoA pour la génération d'ontologies 11
3.3 Validation syntaxique et contrôle qualité des ontologies générées 12
3.4 Enrichissement d'ontologies 13
4 Expérimentations et résultats 13
4.1 Exemples d'ontologies générées 13
4.2 Évaluation par rapport aux ontologies de référence 14
4.3 Cas d'étude : enrichissement d'AGROVOC 15
5 Conclusion 16
6 Bibliographie 17

1 Introduction

Face à la croissance exponentielle des données textuelles et scientifiques, notamment dans le domaine de l'environnement, l'organisation et la structuration des connaissances deviennent des enjeux centraux. Les approches traditionnelles de modélisation des connaissances peinent à suivre ce rythme, tant en raison de la diversité des sources que de l'hétérogénéité des formats. Dans ce contexte, l'utilisation de techniques d'Intelligence Artificielle (IA) de nouvelle génération, et en particulier des grands modèles de langage (LLMs), ouvre de nouvelles perspectives pour l'extraction, la formalisation et la mise en réseau des connaissances. Ces avancées permettent de dépasser les approches manuelles ou semi-automatiques et d'envisager des méthodes plus dynamiques, évolutives et interopérables pour la génération d'ontologies.

Le projet TRACES s'inscrit dans cette dynamique en explorant les potentialités offertes par l'IA pour modéliser et analyser les trajectoires environnementales des territoires. L'un des défis majeurs identifiés concerne la capacité à générer des ontologies à partir de textes, afin d'alimenter et d'enrichir les graphes de connaissances environnementaux. Dans cette optique, les LLMs et l'IA agentique constituent des leviers particulièrement prometteurs. En effet, au-delà de leur puissance de traitement linguistique, ces outils offrent la possibilité de coordonner des agents spécialisés capables de collaborer dans des chaînes d'opérations, comme le propose le paradigme Chain-of-Agents (CoA). Ce type d'approche permet d'automatiser la détection des concepts, l'extraction des relations et la structuration des connaissances dans un format ontologique standardisé, garantissant ainsi une meilleure intégration avec les vocabulaires environnementaux existants.

L'intégration de ces ontologies générées dans des référentiels publics tels qu'AGROVOC représente un enjeu crucial pour le projet TRACES. Elle permet non seulement d'enrichir les vocabulaires contrôlés existants, mais aussi de renforcer leur capacité à couvrir des domaines émergents ou insuffisamment décrits. Cette articulation entre génération automatique et enrichissement sémantique contribue directement à la création de trajectoires environnementales sémantiques des territoires (SETTs), qui constituent le cœur du projet. En outre, elle offre une voie prometteuse pour renforcer l'interopérabilité et l'explicabilité des systèmes d'information environnementaux, en cohérence avec les principes FAIR (Findable, Accessible, Interoperable, Reusable).

L'utilisation de l'IA agentique pour la génération d'ontologies soulève toutefois des questions méthodologiques et pratiques : comment évaluer la qualité des ontologies produites ? Comment mesurer leur concision, leur complétude et leur correction par rapport à des ontologies de référence ? Quelles limites apparaissent dans les scénarios d'usage réels, et quelles pistes d'amélioration envisager ? Ces interrogations sont au cœur de l'analyse présentée dans ce rapport.

Celui-ci s'articule en quatre sections principales, précédées de la présente introduction et suivies d'une conclusion. La première section propose un état de l'art sur la génération d'ontologies, en mettant en perspective les approches classiques et les apports récents des LLMs et de l'IA agentique. La deuxième section décrit la méthodologie adoptée dans TRACES, en détaillant le pipeline de génération d'ontologies basé sur le paradigme CoA. La

troisième section présente les expérimentations réalisées, avec des exemples concrets et une évaluation comparative. Enfin, la quatrième section discute des résultats obtenus, de leurs limites et des perspectives offertes par cette approche dans le contexte plus large de la recherche environnementale et du Web sémantique.

2 État de l'art

2.1 Ontologie et apprentissage d'ontologies : définitions et approches classiques

Le terme ontologie, issu de la philosophie, a été adopté en informatique et en sciences de l'information pour désigner une spécification explicite et formelle d'une conceptualisation partagée [Gruber, 1993]. Une ontologie décrit un domaine de connaissances à travers un ensemble de concepts (ou classes), de relations entre ces concepts, ainsi que d'instances et d'axiomes permettant de contraindre et de formaliser leur usage. Dans le contexte du Web sémantique, les ontologies sont généralement exprimées à l'aide de langages standards tels que RDF (Resource Description Framework), RDFS (RDF Schema) ou OWL (Web Ontology Language), qui permettent de représenter les connaissances sous une forme exploitable par les machines et interopérable entre systèmes.

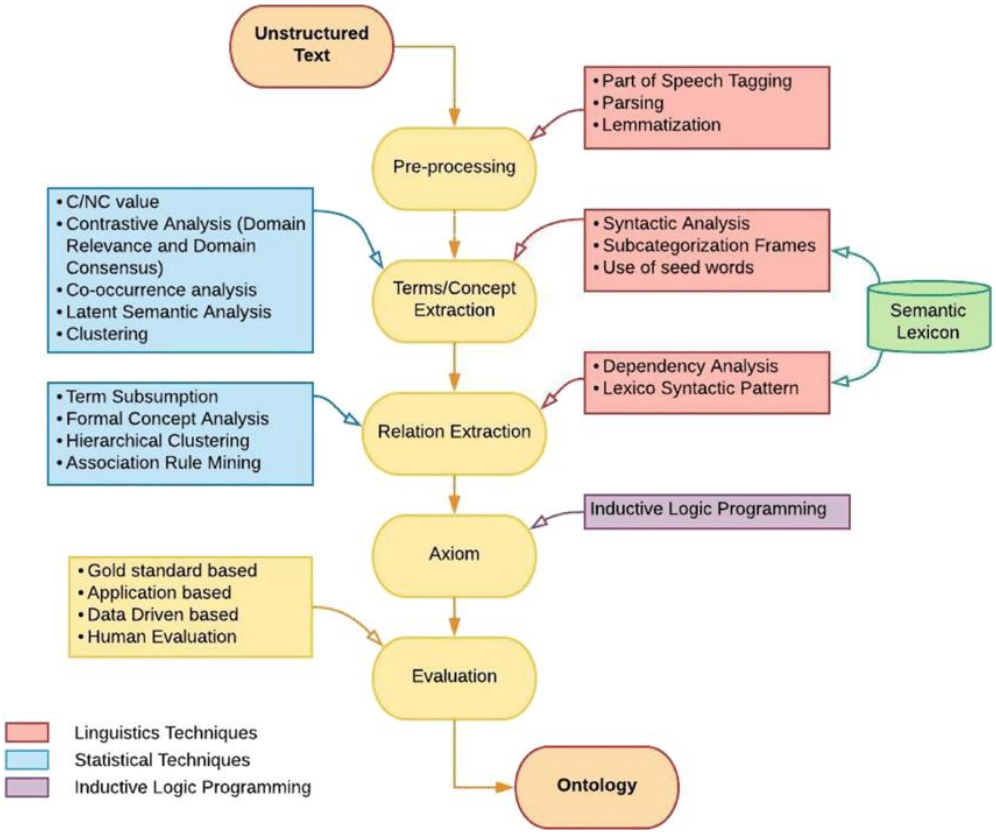


Figure 1 - Schéma général du processus d'apprentissage d'ontologies à partir de textes non structurés

L'apprentissage d'ontologies (Ontology Learning) désigne l'ensemble des méthodes et techniques visant à automatiser, totalement ou partiellement, la construction d'ontologies à partir de sources de données. Ces sources peuvent être des textes non structurés (articles scientifiques, rapports, bases documentaires), des données semi-structurées (bases relationnelles, fichiers XML), ou encore des données structurées (bases de connaissances existantes, jeux de données RDF). L'objectif est de réduire la charge manuelle liée à l'ingénierie ontologique et de faciliter l'adaptation des ontologies à l'évolution des connaissances.

Historiquement, plusieurs approches classiques d'apprentissage d'ontologies ont été développées :

- Approches linguistiques : Les approches linguistiques exploitent les techniques du Traitement Automatique du Langage Naturel (NLP) pour extraire des termes candidats et leurs relations à partir de textes.
    - Extraction terminologique : repose sur des outils comme les analyseurs morphosyntaxiques et les extracteurs de termes (par ex. TermExtractor, Text2Onto [Cimiano & Völker, 2005]). Ces systèmes identifient des syntagmes nominaux fréquents (p. ex. climate change, carbon emission) comme candidats-concepts.
    - Patrons lexicaux (Hearst patterns) : proposés par [Hearst, 1992], ils permettent d'identifier automatiquement des relations hiérarchiques. Exemple : dans la phrase "such as apples, oranges and other fruits", le patron "X such as Y" permet d'inférer la relation apples est-un fruit. Ces patrons ont été largement utilisés pour peupler des hiérarchies.
    - Analyse de dépendances syntaxiques : permet d'identifier les relations plus complexes entre concepts, comme les relations causales (pollution causes biodiversity loss).

  Ces approches sont efficaces pour extraire des relations explicites, mais elles souffrent de faible rappel (elles ne détectent que ce qui est exprimé dans des constructions linguistiques connues) et de forte dépendance au domaine.

- Approches statistiques et basées sur le machine learning : Les approches statistiques considèrent que la distribution des termes dans un corpus reflète leurs liens sémantiques.
    - Cooccurrence et distributional semantics : deux termes apparaissant fréquemment dans les mêmes contextes textuels peuvent être considérés comme liés (ex. soil et erosion). Cette idée s'appuie sur l'hypothèse distributionnelle de Harris [1954].
    - Mesures de similarité : TF-IDF, PMI (Pointwise Mutual Information), ou encore embeddings vectoriels (LSA, Word2Vec [Mikolov et al., 2013]) permettent de proposer des regroupements de termes.

- Clustering hiérarchique : utilisé pour inférer des taxonomies en regroupant les termes selon leur similarité contextuelle [Faure & Nedellec, 1999].
- Classification supervisée : lorsqu'un corpus annoté existe, des modèles d'apprentissage peuvent prédire le rôle d'un terme (concept, propriété, instance).

Ces approches permettent de traiter de grands volumes de données, mais elles produisent souvent des structures peu interprétables et nécessitent une phase de validation humaine.

- Approches symboliques et basées sur des règles : Ces méthodes s'appuient sur la logique formelle et sur des règles expertes pour construire ou enrichir une ontologie.

  Elles mobilisent des patrons logiques (ex. si "X is a Y" apparaît régulièrement → inférer une hiérarchie).

  Les systèmes à base de règles comme OntoLearn [Navigli et Velardi, 2004] ou DOGMA [Spyns et al., 2002] combinent dictionnaires, ressources lexicales (WordNet) et règles pour construire des ontologies.

  Elles garantissent une précision élevée mais souffrent d'un manque de scalabilité : il faut élaborer manuellement des règles pour chaque domaine.

- Approches hybrides : La plupart des systèmes modernes combinent plusieurs de ces techniques. Par exemple :

  Text2Onto [Cimiano & Völker, 2005] associe extraction linguistique et pondération statistique.

  OntoLearn Reloaded [Navigli et al., 2011] utilise un mélange de patrons linguistiques et de similarité distributionnelle pour enrichir WordNet et construire des taxonomies.

  Les approches hybrides cherchent à exploiter la complémentarité : la précision des règles linguistiques et la couverture des méthodes statistiques.

Malgré leurs apports, ces approches classiques présentent des limitations notables. Elles peinent à capturer la polysémie et la complexité des relations sémantiques exprimées dans le langage naturel, nécessitent souvent un important travail de prétraitement, et génèrent des résultats fragmentaires ou difficilement exploitables sans intervention humaine. Ces limites expliquent l'intérêt croissant pour l'utilisation de modèles plus puissants et contextuels, tels que les LLMs, qui seront présentés dans la section suivante.

2.2 Apports des LLMs et IA Agentique à l'extraction de connaissances

L'arrivée des LLMs a profondément transformé le domaine de l'extraction de connaissances et, par extension, celui de l'apprentissage d'ontologies. Contrairement aux méthodes classiques, limitées par des règles figées ou des modèles statistiques simples, les LLMs offrent une compréhension contextuelle du langage naturel, capable de capturer des

nuances sémantiques complexes. En s'appuyant sur des milliards de paramètres et des corpus d'entraînement hétérogènes, ces modèles disposent d'une capacité remarquable à identifier des concepts émergents, à générer des relations implicites et à structurer les connaissances sous une forme exploitable.

Par exemple, l'approche LLMs4OL [Babaei Giglou et al,. 2023] explore la capacité des LLMs à accomplir trois tâches clés: typage de termes, découverte de taxonomies et extraction de relations non-taxonomiques, en mode zéro-shot sur des jeux de données variés comme WordNet, GeoNames et UMLS.

Plusieurs usages des LLMs dans la génération et l'enrichissement d'ontologies peuvent être identifiés :

- **Extraction terminologique et de concepts** : les LLMs sont capables de proposer automatiquement des candidats-concepts à partir d'articles scientifiques, de rapports ou de corpus spécialisés. Contrairement aux approches linguistiques classiques, ils peuvent reconnaître des synonymes, des paraphrases ou des variantes lexicales.
- **Extraction de relations** : au-delà des hiérarchies simples, les LLMs permettent d'identifier des relations causales, spatiales ou fonctionnelles présentes dans le texte, même lorsqu'elles ne sont pas exprimées sous des patrons lexicaux explicites. Des travaux récents ont montré que ChatGPT pouvait produire des triplets RDF corrects directement à partir de textes encyclopédiques.
- **Structuration et formalisation** : les LLMs peuvent générer des représentations structurées dans des formats standards (RDF/OWL). Par exemple, des prompts adaptés permettent de demander directement à un modèle de produire des axiomes OWL, ce qui réduit l'écart entre extraction de connaissances et intégration dans un graphe de connaissances [Kapanipathi et al., 2021].
- **Alignement et enrichissement** : un autre apport essentiel réside dans la capacité des LLMs à aligner des concepts nouveaux avec des vocabulaires existants, en utilisant la sémantique contextuelle pour détecter des équivalences ou des relations proches avec des ressources comme AGROVOC, GEMET ou DBpedia.

Plusieurs méthodes récentes illustrent les usages concrets des LLMs pour la génération d'ontologies. OntoGPT, développé comme une bibliothèque Python, permet d'extraire des informations structurées à partir de textes en combinant des prompts adaptés et un enracinement ontologique. NeOn GPT prolonge la méthodologie NeOn en intégrant les capacités des LLMs pour produire directement des ontologies en Turtle à partir de descriptions textuelles. Dans une perspective d'enrichissement ciblé, certains travaux utilisent les LLMs pour identifier des axiomes de disjonction entre classes, améliorant ainsi la consistance logique d'ontologies établies. Enfin, OLLM [Lo, Andy et al,. 2024] propose un modèle de bout en bout qui construit une taxonomie complète à partir de zéro, en affinant un LLM afin de préserver à la fois l'intégrité structurelle et la fidélité sémantique.

Ces apports présentent toutefois certaines limites. Les LLMs peuvent halluciner, c'est-à-dire produire des assertions syntaxiquement correctes mais factuellement incorrectes surtout dans des domaines spécialisés.

Pour renforcer la fiabilité des résultats, plusieurs travaux ont proposé d'intégrer les LLMs dans des architectures d'IA agentique. Celles-ci reposent sur la coopération d'agents distincts, chacun étant chargé d'une tâche spécifique. Cette organisation permet de mieux structurer le processus, de rendre le raisonnement plus explicite et de faciliter la validation intermédiaire des résultats. L'approche multi-agent offre ainsi des garanties accrues en termes de précision, de transparence et de reproductibilité.

Dans nos travaux on a exploré l'architecture CoA qui propose une collaboration entre plusieurs agents LLM, chacun ayant une fonction métier : extraction de termes, inférence de relations, formalisation OWL/RDF, validation, alignement ontologique, etc. Le modèle CoA est particulièrement efficace et scalable pour gérer des tâches longues ou complexes en les découpant en étapes séquentielles, chacune exécutée par un agent spécialisé. Ce paradigme, introduit pour des tâches de long contexte donne une meilleure performance que les approches de type RAG ou les LLMs à longue fenêtre contextuelle.

l'IA agentique conduit à des solutions neuro-symboliques puissantes. Les LLMs fournissent une compréhension linguistique profonde et des capacités génératives, tandis que les agents spécialisés structurent le flux, injectent des règles, effectuent des validations logiques, et assurent l'interopérabilité avec les référentiels existants.

2.3 Approach Chain-of-Agents (CoA)

Parmi les différentes approches développées dans le domaine de l'IA agentique, le modèle CoA propose une manière structurée de coordonner plusieurs agents basés sur des LLMs pour accomplir des tâches complexes. Contrairement à des architectures où les agents travaillent en parallèle, CoA repose sur une exécution séquentielle dans laquelle chaque agent traite une partie du problème et transmet ses résultats à l'agent suivant.

Le fonctionnement de cette approche repose sur une chaîne de traitement : un premier agent commence par analyser une portion du texte ou accomplir une sous-tâche spécifique (par exemple, extraire des concepts), puis génère une sortie intermédiaire (résumé, liste, structure). Cette sortie est transmise à un second agent chargé de la tâche suivante (comme relier les concepts ou générer des relations ontologiques), et ainsi de suite. En fin de chaîne, un agent de synthèse rassemble l'ensemble des éléments produits pour générer un résultat complet. Chaque agent travaille donc avec une partie réduite du contexte global, mais en s'appuyant sur les résultats précédents.

Cette structuration présente plusieurs avantages. D'abord, elle permet de décomposer une tâche complexe en étapes simples, rendant le processus plus transparent et modulaire. Ensuite, chaque agent peut être spécialisé sur un type de traitement précis, ce qui améliore la cohérence globale du pipeline. De plus, comme les agents ne traitent qu'un volume limité d'information à la fois, cette approche contourne partiellement les limitations de fenêtre contextuelle des LLMs, tout en facilitant la gestion des documents longs.

Cependant, cette approche présente aussi certaines limites. Le passage d'informations d'un agent à l'autre peut entraîner une perte de contexte ou des effets de déformation si les sorties intermédiaires sont mal formulées. L'enchaînement strict peut également rendre l'ensemble du processus sensible aux erreurs en amont : une erreur introduite tôt dans la chaîne peut se propager jusqu'à la sortie finale. Par ailleurs, bien que l'approche soit "training-free", elle nécessite un paramétrage précis des rôles et des instructions de chaque agent pour garantir des résultats fiables.

Dans le cadre du projet TRACES, l'approche CoA est utilisée pour structurer le processus de génération d'ontologies à partir de documents environnementaux. Chaque étape de l'extraction de concepts à la formalisation RDF, en passant par l'inférence de relations ou l'alignement avec des vocabulaires existants est confiée à un agent distinct. Cette organisation permet de contrôler finement chaque phase de la chaîne de traitement, tout en exploitant les capacités des LLMs de manière progressive et ciblée. La section suivante détaillera précisément la manière dont cette approche a été mise en œuvre.

3 Méthodologie

3.1 Sources textuelles et corpus utilisés

Pour tester l'application concrète de notre approche CoA dans un cas d'usage réel, nous avons constitué un corpus de documents traitant de la mobilité urbaine à Genève, en Suisse. Ce cas d'étude croise deux domaines complémentaires : d'une part, la structure du réseau de tramway genevois (infrastructures, lignes, véhicules, organisation spatiale), et d'autre part, les politiques publiques liées à la mobilité, à l'aménagement du territoire et à la gouvernance des transports.

Les documents ont été collectés manuellement à partir de sources accessibles en ligne. Le corpus se compose de deux ensembles distincts. Le premier regroupe des articles encyclopédiques, des pages d'information locales et des contenus médiatiques traitant des lignes de tramway existantes et de leurs extensions récentes. Le second ensemble contient des textes plus institutionnels : lois, rapports de planification, publications officielles et documents de stratégie liés à la mobilité et à l'urbanisme.

Cette double approche nous permet de travailler sur des types de contenus textuels variés, mêlant descriptions techniques, narration journalistique et langage administratif. Ces différences de registre constituent un contexte pertinent pour évaluer la robustesse et la polyvalence de notre chaîne d'agents.

Voici quelques exemples de documents utilisés dans le corpus :

- Des pages Wikipédia sur les lignes 13, 14, 15, 17 et 18 du tramway genevois (versions de décembre 2023 à janvier 2024).
- Des articles de presse locale, comme ceux du Dauphiné libéré ou de Léman Bleu TV, couvrant les projets de piétonnisation ou l'inauguration de nouvelles extensions.

- Des sites d'information institutionnelle tels que « tram-pietonnisation.fr » ou « paysdegexagglo.fr », décrivant les travaux et projets de prolongement des lignes.
- Des documents officiels publiés par la République et canton de Genève, comme la loi sur le réseau des transports publics (LRTP) ou le dossier de mise en service du Léman Express.
- Un rapport scientifique (EPFL, 2012) analysant les logiques de choix modal chez les usagers motorisés en milieu urbain.

Ces sources, bien que hétérogènes, convergent vers une compréhension globale de l'évolution des infrastructures et des logiques de gouvernance de la mobilité à l'échelle urbaine et transfrontalière. Elles servent de base à la génération des ontologies présentées dans les sections suivantes.

3.2 CoA pour la génération d'ontologies

Dans notre approche, le cadre CoA est utilisé pour structurer la génération d'ontologies à partir de textes. L'idée est de répartir le travail entre plusieurs agents de type LLM. Les agents dits workers traitent chacun un segment du corpus, identifient les concepts, relations et hiérarchies, puis produisent une ontologie partielle en format OWL/Turtle. Un agent manager prend ensuite en charge l'intégration de ces ontologies partielles en une version unifiée, en supprimant les redondances et en vérifiant la cohérence de l'ensemble.

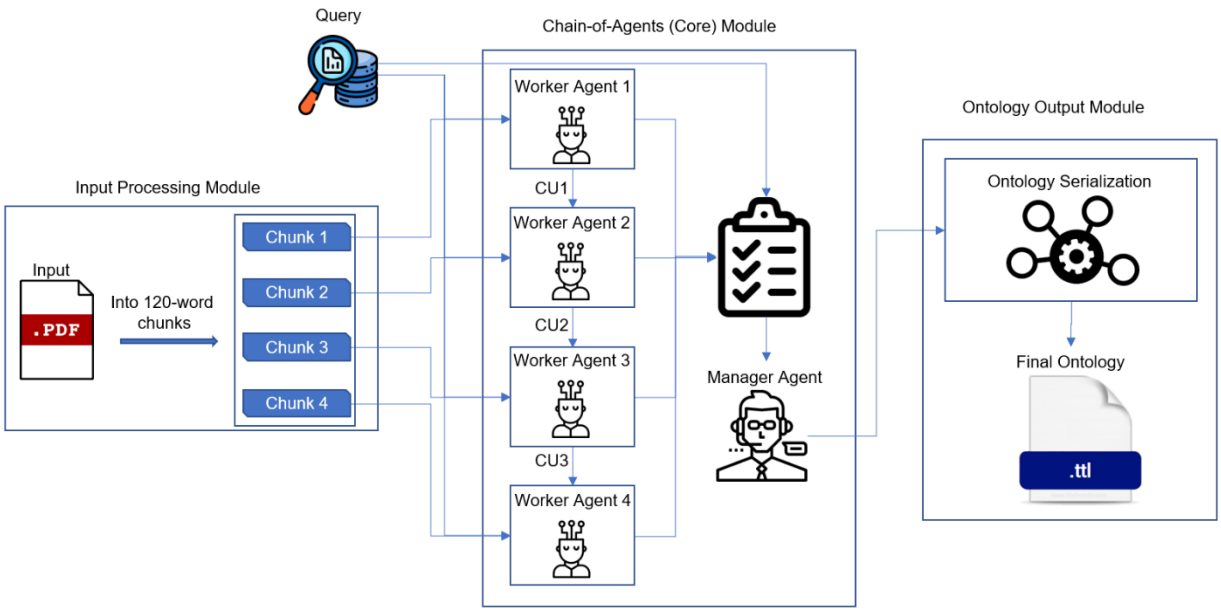


Figure 2 – CoA-Text2OWL Framework

Dans notre travail, cette approche a été intégrée au modèle Text2OWL, qui permet de traduire un texte en ontologie formalisée en OWL/Turtle. Les agents dits workers reçoivent chacun un segment de texte et produisent un extrait d'ontologie comprenant des classes,

sous-classes et propriétés. Le manager rassemble ensuite ces extraits en supprimant les redondances, en harmonisant les relations et en veillant à la conformité syntaxique avec les standards du Web sémantique. Cette organisation en chaîne permet de préserver la cohérence tout en tirant parti de la puissance des modèles de langage sur des textes plus longs et plus complexes.

Les expériences menées ont montré que le recours à CoA améliore certains aspects clés de la génération d'ontologies. L'extraction des propriétés d'objet est plus complète que dans l'approche à agent unique, et la concision des classes est mieux assurée, ce qui réduit le bruit et les concepts superflus. En revanche, des limites subsistent, notamment pour la reconstitution des hiérarchies de classes (subClassOf), qui restent incomplètes. L'approche multi-agent ne supprime pas totalement les problèmes liés à la couverture conceptuelle, ni les variations aléatoires propres aux modèles de langage.

Malgré ces limites, CoA présente des atouts intéressants pour le projet TRACES. La segmentation du texte et la distribution des tâches facilitent l'extraction d'ontologies à partir de corpus volumineux et hétérogènes. L'approche se prête bien à l'enrichissement de vocabulaires environnementaux comme AGROVOC, car elle permet de contrôler séparément les étapes d'extraction, de formalisation et d'alignement. Dans la suite de ce rapport, nous décrivons comment ce cadre a été appliqué aux données textuelles collectées pour TRACES, en vue de générer des ontologies environnementales et d'évaluer leur qualité.

3.3 Validation syntaxique et contrôle qualité des ontologies générées

Une fois les ontologies produites par la chaîne d'agents, une étape de validation syntaxique est nécessaire afin de garantir leur conformité avec les standards du Web sémantique. Les ontologies générées sont sérialisées en format OWL/Turtle puis soumises à un contrôle automatisé à l'aide de bibliothèques spécialisées (par exemple rdflib en Python ou les outils de validation intégrés à Protégé). Cette vérification permet de détecter les erreurs de syntaxe, les incohérences dans la déclaration des classes et propriétés, ainsi que les doublons ou éléments redondants introduits lors de la fusion des sous-ontologies par l'agent manager.

En complément de cette validation syntaxique, un contrôle qualité a été appliqué pour évaluer la pertinence et la robustesse des ontologies produites. Trois indicateurs sont mobilisés : la conciseness, qui mesure la proportion d'éléments pertinents par rapport à l'ensemble des concepts générés ; la completeness, qui évalue la couverture des connaissances de référence ; et la correctness, qui combine les deux dimensions précédentes sous la forme d'un F-mesure. Ces métriques permettent de comparer les ontologies obtenues à une ontologie de référence, en mettant en évidence à la fois les apports et les manques.

Enfin, afin de mieux apprécier la qualité sémantique des ontologies produites dans TRACES, nous avons complété ces mesures classiques par une comparaison avec les textes sources. Pour cela, les ontologies ont été converties en résumés textuels, puis comparées aux

documents d'origine à l'aide de mesures de similarité sémantique basées sur les embeddings multilingues de BERT. Cette approche fournit une indication supplémentaire sur la fidélité des ontologies générées par rapport au contenu initial, en particulier dans des contextes où il n'existe pas toujours d'ontologie de référence établie.

L'ensemble de ces validations garantit que les ontologies produites ne se limitent pas à un simple respect syntaxique, mais qu'elles conservent également une cohérence interne et une correspondance avec les connaissances du domaine étudié.

3.4 Enrichissement d'ontologies

Les ontologies produites par la chaîne d'agents ont ensuite été utilisées pour enrichir des vocabulaires contrôlés existants dans le domaine de l'environnement. Cette étape vise à relier les nouvelles entités identifiées dans les corpus textuels avec des ressources de référence telles qu'AGROVOC, afin de renforcer leur couverture conceptuelle et de faciliter leur réutilisation dans des contextes applicatifs.

L'enrichissement s'appuie sur un processus d'alignement sémantique. Les concepts extraits dans les ontologies générées sont comparés aux termes existants dans le vocabulaire cible à l'aide d'embeddings vectoriels. Les étiquettes de chaque concept ont été représentées par des vecteurs grâce à des modèles de langage préentraînés, puis rapprochées des représentations disponibles dans AGROVOC. La similarité cosinus est utilisée comme critère principal pour identifier les correspondances potentielles entre concepts. Lorsque le score dépasse un seuil défini, une relation d'équivalence ou d'association est proposée entre le concept nouvellement généré et l'entrée du vocabulaire contrôlé.

Ce mécanisme permet de combler certaines lacunes des vocabulaires standards, en particulier pour des notions émergentes ou spécifiques aux contextes étudiés. Par exemple, les documents relatifs à la mobilité urbaine ou aux infrastructures de transport ont fait apparaître des termes peu couverts dans AGROVOC. Leur alignement avec des concepts proches assure leur intégration progressive au sein d'un réseau de connaissances plus large et interopérable.

4 Expérimentations et résultats

4.1 Exemples d'ontologies générées

L'approche Chain-of-Agents a été appliquée aux deux corpus textuels décrits dans la méthodologie afin de produire des ontologies représentatives des domaines étudiés. La première ontologie concerne le réseau de tramway genevois et ses extensions, tandis que la seconde porte sur les politiques publiques de mobilité et de gouvernance des transports.

L'ontologie générée à partir du corpus sur le tramway regroupe des classes décrivant les lignes, stations, véhicules et infrastructures associées. Des relations permettent d'établir les liens entre ces entités, par exemple l'appartenance d'une station à une ligne ou la desserte d'une zone spécifique par un tronçon donné. L'ontologie inclut également des notions relatives aux projets d'extension, telles que les prolongements vers Annemasse ou Ferney-

Voltaire. Ces éléments traduisent la capacité du pipeline CoA à capter les spécificités locales et à formaliser la structure spatiale et fonctionnelle du réseau.

La seconde ontologie, produite à partir du corpus institutionnel, met en évidence les principaux concepts liés aux mesures de planification et à la réglementation de la mobilité urbaine. On y retrouve notamment des classes relatives aux lois, plans stratégiques, dispositifs d'accompagnement et acteurs institutionnels impliqués. Des relations hiérarchiques et associatives organisent ces concepts, par exemple entre une politique publique et les mesures concrètes qu'elle encadre. L'ontologie permet ainsi de représenter de manière structurée l'articulation entre objectifs réglementaires et dispositifs opérationnels.

Ces exemples montrent que, même à partir de textes hétérogènes, le cadre CoA permet de produire des ontologies exploitables, différenciées selon les domaines étudiés. Les structures obtenues traduisent à la fois les entités matérielles (réseau de transport, infrastructures) et les dimensions organisationnelles (régulation, gouvernance), offrant une base pour leur intégration ultérieure dans des graphes de connaissances environnementaux plus larges.

4.2 Évaluation par rapport aux ontologies de référence

L'évaluation des ontologies générées dans TRACES s'est appuyée sur une comparaison avec les ontologies de référence et, lorsque cela était pertinent, avec les textes sources eux-mêmes. L'objectif était de mesurer à la fois la conformité structurelle des ontologies produites et leur fidélité sémantique par rapport aux connaissances du domaine.

Table 1. Comparison of OWL axioms counts for the Pizza Ontology, CoA-Text2OWL, and baseline.

Count	Pizza Ontology	CoA-Text2OWL	Baseline
Named Classes	97	33	23
Object Properties	8	2	0
Named Individuals	5	0	0
Indiv. (ObjProps)	5	0	0
SubClassOf Tuples	141	32	23

Trois métriques ont été utilisés : conciseness, completeness et correctness. dans un premier temps, ils ont été appliquées à des corpus standards (ontologie de la pizza) afin d'établir un point de comparaison entre l'approche CoA-Text2OWL et une version classique de Text2OWL utilisant les LLMs. Les résultats ont montré que CoA améliore nettement l'extraction des propriétés d'objet, atteignant un score de conciseness de 1,0 et une meilleure couverture des relations, alors que le modèle de base n'extrait aucune propriété. En revanche, la hiérarchie des classes (subClassOf) reste un point faible, avec une couverture inférieure à celle du modèle de référence. Sur les classes elles-mêmes, CoA obtient une meilleure précision en évitant les concepts inutiles, mais une complétude encore limitée.

Table 2. Comparison of OL performance between CoA-Text2OWL and the baseline method using Mistral-7B.

Metrics	CoA-Text2OWL	Baseline
Classes conciseness	0.84	**1.00**
Classes completeness	**0.29**	0.25
Classes correctness	**0.43**	0.41
Object properties conciseness	**1.00**	0.00
Object properties completeness	**0.25**	0.00
Object properties correctness	**0.40**	0.00
SubClassOf pairs conciseness	0.12	**0.56**
SubClassOf pairs completeness	0.01	**0.05**
SubClassOf pairs correctness	0.02	**0.09**

Dans un second temps, l'évaluation a été appliquée aux corpus TRACES. Chaque ontologie produite (tramway et politiques publiques) a été convertie en résumé textuel, puis comparée aux documents d'origine par des mesures de similarité sémantique. Les embeddings de Multilingual BERT (mBERT) ont servi de base pour calculer la similarité cosinus entre les résumés ontologiques et les segments de texte correspondants. Les scores obtenus sont élevés dans les deux cas (0,935 pour le tramway et 0,926 pour les politiques publiques), ce qui indique une bonne correspondance conceptuelle. Les métriques lexicales (ROUGE et BLEU) donnent des résultats plus faibles, ce qui reflète le caractère plus abstrait du langage généré à partir d'ontologies, mais confirment la présence d'unités lexicales pertinentes dans les sorties.

Table 3. Evaluation results for ontology-document semantic similarity.

Ontology	BERTScore	ROUGE-1	ROUGE-2	BLEU-1	BLEU-2
Tramway Network	0.935	0.365	0.059	0.240	0.079
Mobility Policy	0.926	0.392	0.089	0.249	0.098

4.3 Cas d'étude : enrichissement d'AGROVOC

Le processus d'alignement a permis d'identifier plusieurs correspondances pertinentes. Dans le cas du corpus relatif au tramway genevois, des concepts liés aux infrastructures de transport, aux lignes et aux stations ont été rapprochés de termes déjà présents dans AGROVOC, principalement dans les catégories « transport » et « infrastructures ». Certains concepts spécifiques, comme les prolongements vers Annemasse ou Ferney-Voltaire, n'avaient pas d'équivalent direct et ont été proposés comme candidats à l'extension du vocabulaire.

Du côté des politiques publiques, l'alignement a permis de relier des notions réglementaires et stratégiques, telles que les lois cantonales, les plans de mobilité et les mesures d'accompagnement, à des entrées plus générales d'AGROVOC couvrant la gouvernance, l'aménagement du territoire et la planification environnementale. Ici encore, plusieurs termes relatifs à la gouvernance locale et transfrontalière ne figuraient pas dans le vocabulaire existant et constituent des ajouts potentiels pour enrichir la base.

La qualité de l'enrichissement a été mesurée à l'aide de la similarité cosinus entre les vecteurs d'embeddings des concepts générés et ceux des étiquettes d'AGROVOC. Les résultats montrent une proportion significative de correspondances avec un score élevé, ce qui confirme la pertinence des alignements proposés. Les concepts dont les scores étaient plus faibles ont fait l'objet d'une vérification manuelle, permettant de corriger certaines ambiguïtés lexicales et d'écarter des correspondances incorrectes.

Ces résultats indiquent que l'approche CoA, combinée à une étape d'alignement sémantique, peut contribuer de manière effective à l'extension de vocabulaires contrôlés.

5 Conclusion

Les travaux menés dans le cadre de TRACES ont permis de tester l'utilisation de l'IA agentique et des grands modèles de langage pour la génération et l'exploitation d'ontologies à partir de textes environnementaux. L'approche CoA a montré son intérêt pour structurer le processus de génération, en répartissant les tâches entre plusieurs agents spécialisés. Les résultats obtenus soulignent une meilleure capacité d'extraction des relations et des propriétés d'objet, même si des limites subsistent concernant la couverture hiérarchique et la complétude des classes.

La méthodologie mise en place a permis d'illustrer le potentiel d'un pipeline multi-agent appliqué à des corpus hétérogènes, allant de descriptions techniques d'infrastructures à des textes institutionnels. Les ontologies générées constituent une première base exploitable, à la fois pour représenter des connaissances locales et pour contribuer à l'enrichissement de vocabulaires contrôlés comme AGROVOC. L'étape d'alignement a confirmé la pertinence d'intégrer des concepts issus de textes spécialisés dans un vocabulaire internationalement reconnu, renforçant ainsi l'interopérabilité des données produites.

Ces résultats ouvrent plusieurs perspectives. Sur le plan méthodologique, des améliorations peuvent être envisageables pour renforcer la qualité des ontologies produites, notamment en affinant la capture des relations hiérarchiques et en développant des mécanismes de validation sémantique plus robustes. Sur le plan applicatif, l'approche pourrait être étendue à d'autres corpus environnementaux, en lien avec des modèles conceptuels tels que DPSIR, afin de produire des trajectoires environnementales sémantiques plus riches et plus interopérables.

En conclusion, l'utilisation combinée des LLMs et de l'IA agentique offre des perspectives solides pour l'automatisation de l'apprentissage d'ontologies dans le domaine de l'environnement. Les expérimentations réalisées dans TRACES constituent une première étape vers des systèmes capables de produire et de relier des connaissances de manière plus systématique, tout en s'intégrant dans des vocabulaires partagés et des infrastructures de données ouvertes.

6 Bibliographie

[1] Cimiano, Philipp, and Johanna Völker. "Text2onto: A framework for ontology learning and data-driven change discovery." International conference on application of natural language to information systems. Berlin, Heidelberg: Springer Berlin Heidelberg, 2005. core.ac.uk/download/pdf/15960224.pdf

[2] Hearst, Marti A. "Automatic acquisition of hyponyms from large text corpora." *COLING 1992 volume 2: The 14th international conference on computational linguistics*. 1992. aclanthology.org/C92-2082.pdf

[3] Harris, Zellig S. "Distributional structure." *Word* 10.2-3 (1954): 146-162. tandfonline.com/doi/pdf/10.1080/00437956.1954.11659520

[4] Faure, David, and Claire Nédellec. "Knowledge acquisition of predicate argument structures from technical texts using machine learning: The system ASIUM." International Conference on Knowledge Engineering and Knowledge Management. Berlin, Heidelberg: Springer Berlin Heidelberg, 1999. ndl.ethernet.edu.et/bitstream/123456789/20501/1/155.pdf#page=337

[5] Velardi, Paola, Stefano Faralli, and Roberto Navigli. "Ontolearn reloaded: A graph-based algorithm for taxonomy induction." *Computational Linguistics* 39.3 (2013): 665-707. watermark02.silverchair.com/coli_a_00146.pdf

[6] Spyns, Peter, Yan Tang, and Robert Meersman. "An ontology engineering methodology for DOGMA." *Applied Ontology* 3.1-2 (2008): 13-39. researchgate.net/profile/Yan-Tang-27/publication/220438682

[7] Velardi, Paola, Stefano Faralli, and Roberto Navigli. "Ontolearn reloaded: A graph-based algorithm for taxonomy induction." *Computational Linguistics* 39.3 (2013): 665-707. https://watermark02.silverchair.com/coli_a_00146.pdf

[8] Babaei Giglou, Hamed, Jennifer D'Souza, and Sören Auer. "LLMs4OL: Large language models for ontology learning." *International Semantic Web Conference*. Cham: Springer Nature Switzerland, 2023. arxiv.org/pdf/2307.16648

[9] Neelam, Sumit, et al. "Sygma: System for generalizable modular question answering overknowledge bases." *arXiv preprint arXiv:2109.13430* (2021). arxiv.org/pdf/2109.13430

[10] Babaei Giglou, Hamed, Jennifer D'Souza, and Sören Auer. "LLMs4OL: Large language models for ontology learning." *International Semantic Web Conference*. Cham: Springer Nature Switzerland, 2023. arxiv.org/pdf/2307.16648

[11] Lo, Andy, et al. "End-to-end ontology learning with large language models." *Advances in Neural Information Processing Systems* 37 (2024): 87184-87225. https://proceedings.neurips.cc/paper_files/paper/2024/

[12] Asim, Muhammad & Wasim, Muhammad & Khan, Muhammad Usman & Mahmood, Waqar. A survey of ontology learning techniques and applications. Database The Journal of

Biological Databases and Curation. 2018. 1–24. 10.1093/database/bay101. (2018). Download citation of A survey of ontology learning techniques and applications