Amélioration de l'idiomaticité dans les systèmes de résumés abstractifs

Abdelghani.Laifa[1], Christophe. Cruz[2], Laurent. Gautier[1,2]. (1) LIB/MSH, Université de Bourgogne, (2) LIB, Université de Bourgogne, (3) MSH, Université de Bourgogne Abdelghani_laifa@etu.u-bourgogne.fr

Le résumé automatique de texte n'est pas un nouveau domaine de recherche. Depuis les travaux de [1], de nombreux travaux ont été menés pour en améliorer les résultats. Le résumé automatique de texte (RAT) est actuellement un domaine de recherche actif dans le traitement du langage naturel (TALN). La tâche de RAT consiste à capturer les informations importantes d'un texte pour produire un texte plus court. Il existe dans ce contexte deux types de systèmes de résumé automatique de texte : extractif et abstractif. Le résumé abstractif consiste à générer un résumé en utilisant des mots nouveaux pour reformuler l'idée principale d'un article [2], tandis que le résumé extractif consiste à découper et assembler des parties du texte existant pour en produire une version condensée " [3].

La plupart du temps, les méthodes des résumés automatiques visent à générer un résumé informatif (en couvrant les informations essentielles), mais le critère de l'idiomaticité, qui garantit la lisibilité pour l'utilisateur final, est souvent négligé, notamment dans les textes propres à un domaine de spécialité donné comme la finance en France dans notre cas. Ce critère repose sur des schémas lexico-grammaticaux [4] (une combinaison particulière et récurrente d'éléments lexicaux et de grammaire). La présence de ces schémas dans un texte produit automatiquement fait en effet « sentir » que ce texte a été fait par un humain et non pas une machine.

Pour relever ce défi, nous nous sommes donc concentrés sur cet axe d'idiomaticité / fluidité afin d'améliorer la qualité des résumés générés par le modèle abstractif de résumé automatique dans le domaine de la finance en France. Dans [6], cet axe a été d'amélioré de 6% à 11% dans le modèle extractif de résumés automatiques dans le domaine de finance en France.

La figure 1 explique notre méthode, nous avons choisi un modèle pré-entrainé français BARThez [5] entrainé sur des données tirées du Web, ce choix de modèle revient à ses meilleures performances dans la littérature et à sa capacité de traiter les données en français. Nous avons ajusté ce modèle sur notre corpus financier français en deux phases : la première où des contraintes linguistiques définies par l'expert linguiste sont imposées sur le corpus d'ajustement afin d'ajuster un premier modèle abstractif, et une deuxième phase où l'on néglige ces contraintes. Le but étant de comparer les deux modèles (avec/sans contraintes) et montrer l'impact de ces contraintes linguistiques sur l'amélioration de l'idiomaticité des résumés générés. Dans la table 1 nous avons pris deux modèles de base d'évaluation utilisés dans les résumés abstractifs, deux autres modèles français pré-entrainés sur la langue française standard et le modèle BARThez français avant l'ajustement. Le modèle de résumé abstractif dont les contraintes sont injectées offre des résultats meilleurs que les autres modèles en termes de qualité et d'idiomaticité des résumés générés.

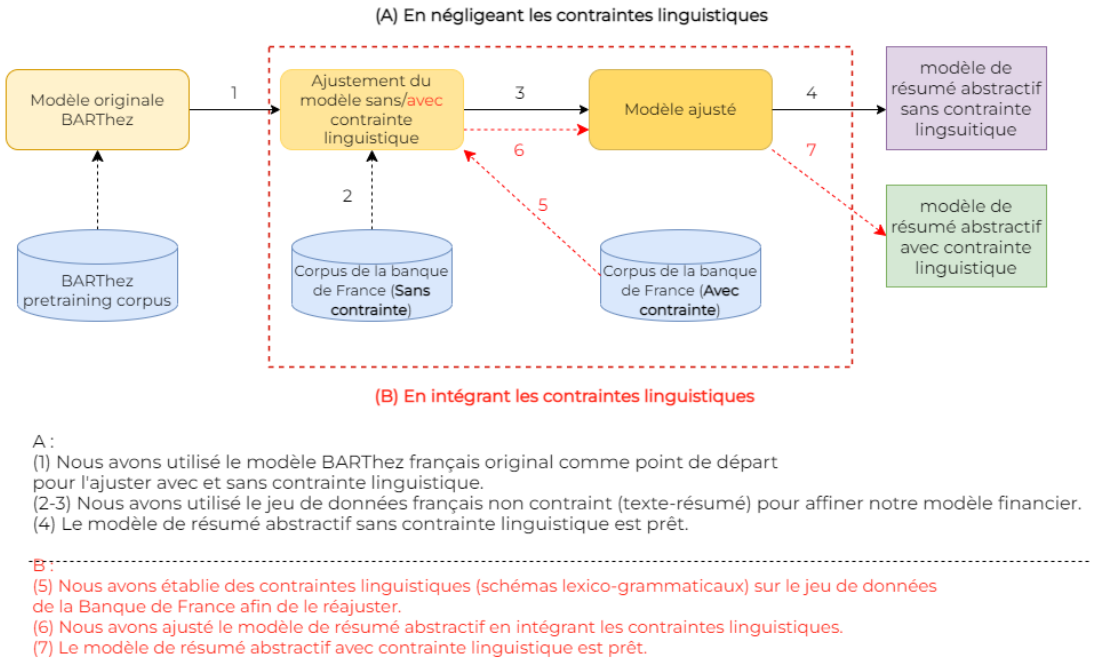

Figure 1: Méthodologie de l'approche abstractive

Modèles	R_1	R_2	R_L	BERTscore_P	BERTscore_R	BERTscore_F1
PAGnol-L (base d'évaluation)	28.12	15.30	24.35	61.77	71.06	65.89
PAGnol-XL (base d'évaluation)	28.63	16.23	25.09	62.29	71.63	66.23
mBART	29.43	18.29	26.17	65.97	72.55	68.33
CamemBERT2CamemBERT	29.58	17.79	26.12	66.36	72.34	68.25
BARThez (avant l'ajustement)	31.21	18.84	26.23	68.91	73.19	69.87
Notre modèle après l'ajustement	**33.84**	20.01	**28.58**	**72.99**	74.01	**73.42**

Table 1: – Comparaison de notre modèle avant/après l'ajustement avec les autres modèles

Références

[1] Luhn, Hans Peter. "The automatic creation of literature abstracts." IBM Journal of research and development 2.2 (1958): 159-165.
[2] Nallapati, Ramesh, Bing Xiang, and Bowen Zhou. "Sequence-to-sequence rnns for text summarization." (2016).
[3] Rush, Alexander M., Sumit Chopra, and Jason Weston. "A neural attention model for abstractive sentence summarization." arXiv preprint arXiv:1509.00685 (2015).
[4] Gledhill, Christopher. "The 'lexicogrammar'approach to analysing phraseology and collocation in ESP texts." ASp. la revue du GERAS 59 (2011): 5-23.
[5] Eddine, Moussa Kamal, Antoine J-P. Tixier, and Michalis Vazirgiannis. "Barthez: a skilled pretrained french sequence-to-sequence model." arXiv preprint arXiv:2010.12321 (2020).
[6] Laifa, Abdelghani, Laurent Gautier, and Christophe Cruz. "Extraire des patterns pour améliorer l'idiomaticité de résumés semi-automatiques en finances: le cas du lexique support." (2021): 113-135.